

Reliable and Trustworthy AI — Assignment #4

1. Problem 1: α, β -CROWN Models Directory 탐색

α, β -CROWN GitHub 저장소의 `complete_verifier/models` 디렉토리에는 MNIST, CIFAR-10/100, ResNet, OVAL, ERAN 등 벤치마크 모델 체크포인트가 포함되어 있다. 아래 표는 주요 파일 형식을 정리한 것이다.

Format	Count	Description
.pth	24	MNIST, CIFAR-10/100, ResNet, OVAL, ERAN benchmark checkpoints
.model	8	SDP-style MNIST/CIFAR legacy benchmark files
.pkl / .py	8	OVAL property files, ResNet 정의, helper scripts

대부분 PyTorch 체크포인트이며, ONNX 모델은 외부 VNN-COMP 벤치마크에서 참조하는 방식이다. `exp_configs` 디렉토리에는 263 개 YAML 설정 파일이 있으며, VNN-COMP 2021–2025, BICCOS, GCP-CROWN, tutorial examples 등으로 분류된다. 각 YAML은 다음 섹션으로 구성된다.

YAML Section	Role
general	device, seed, timeout, complete verifier mode (bab / mip / bab-refine)
model	PyTorch: name + path / ONNX: onnx_path, input_shape
data	dataset, normalization, instance range, custom dataloader
specification	Lp norm + epsilon, element-wise bounds, 또는 vnnlib_path
solver / bab / attack	bound propagation, branch-and-bound, branching, batch size 등

1.1 Marabou와의 명세 방식 차이

Marabou는 Python API에서 ONNX 모델을 읽은 뒤 입력 변수의 bound와 출력 변수 간 선형 constraint를 코드로 직접 설정하는 programmatic 방식이다. 반면 α, β -CROWN은 모델과 solver 설정을 YAML에, 입력 bounds와 출력 property를 VNNLIB 파일에 분리하여 표현하는 configuration-centered 방식이다. 작은 모델에서는 Marabou의 직접 설정이 직관적이지만, 여러 property를 batch 처리하거나 큰 모델을 다룰 때는 α, β -CROWN의 파일 기반 구조가 유리하다.

2. Problem 2: 외부 모델로 α, β -CROWN 실행

2.1 모델과 데이터셋

과제 3에서 Marabou 검증에 사용했던 Wine dataset 기반 MLP를 선택하였다. 모델 구조는 $13 \rightarrow 16 \rightarrow \text{ReLU} \rightarrow 8 \rightarrow \text{ReLU} \rightarrow 3$ 이며, `sklearn.datasets.load_wine()`의 13 개 feature를 StandardScaler로 정규화한 입력을 받아 3 개 class logit을 출력한다. 이 모델을 선택한 이유는 첫째 과제 3과 동일한 모델이므로 두 도구의 결과를 직접 비교할 수 있고, 둘째 입력 차원이 작아 complete verification에 부담이 적으며, 셋째 ReLU 기반 MLP이므로 bound propagation 및 branch-and-bound 방식과 잘 맞기 때문이다.

2.2 검증 설정

검증 대상은 test set에서 정답으로 분류된 low-margin 후보들 중 작은 ϵ 에서는 verified 되고 큰 ϵ 에서는 falsified 되는 `low_margin_3` (예측 class: `class_1`, margin ≈ 4.31)을 사용하였다. 정규화된 입력 공간에서 각 feature에 대해 ℓ_∞ perturbation $x_i - \epsilon \leq x'_i \leq x_i + \epsilon$ 를 부여하고, 출력 property는 "다른 class j의 logit이 원래 class logit 이상이 되는 반례가 존재하는가?"로 정의하였다. 이 unsafe condition을 VNNLIB 파일로 작성하였으므로, α, β -CROWN의 `unsat`은 verified, `sat`은 falsified로 해석하였다. $\epsilon \in \{0.01, 0.05, 0.1, 0.3, 0.5, 1.0\}$ 을 sweep하였다.

호환성 설정으로는 과제 3의 ONNX 모델과 metadata를 복사하고, 각 sample/epsilon에 대해 VNNLIB property 파일을 생성하였다. YAML 설정 파일(`wine_mlp_base.yaml`)에 ONNX 경로, input shape `[-1, 13]`, CPU 실행, timeout 등을 명시하였다.

2.3 검증 결과

모든 ϵ 에서 α, β -CROWN 과 Marabou 의 verified/falsified 판단이 일치하였다. 내부 시간은 verifier 출력 Time 값, wall time 은 Python wrapper 전체 실행 시간이다. method 열은 α, β -CROWN 이 결론에 도달한 방법을 나타낸다.

ϵ	α, β -CROWN	int.(s)	wall(s)	Marabou	time(s)	match	method
0.01	verified	0.193	5.58	verified	0.001	✓	CROWN
0.05	verified	0.185	5.35	verified	0.001	✓	CROWN
0.10	verified	0.185	5.45	verified	0.001	✓	CROWN
0.30	falsified	0.027	5.32	falsified	0.003	✓	PGD
0.50	falsified	0.033	5.27	falsified	0.003	✓	PGD
1.00	falsified	0.026	5.04	falsified	0.003	✓	PGD

$\epsilon \leq 0.10$ 에서는 branch-and-bound 없이 initial CROWN bound 만으로 property 가 verified 되었다. $\epsilon \geq 0.30$ 에서는 PGD attack 이 counterexample 을 빠르게 찾아 falsified 로 판정하였다. 실험한 ϵ sweep 기준으로 robust/non-robust 경계는 0.10 이상 0.30 미만 구간에 있다. 이 구간을 더 좁히려면 $\epsilon = 0.15, 0.20$ 등 중간 값으로 추가 sweep 이 필요하다.

$\epsilon = 0.30, 0.50, 1.00$ 에서는 α, β -CROWN 의 PGD attack 이 unsafe condition 을 만족하는 입력을 찾아 sat 으로 판정하였으며, violation 수는 각각 1, 1, 2 였다. 본 제출물에서는 반례 입력 벡터 전체 대신 결과 JSON 과 실행 로그에 sat 판정, attack 성공 여부, violation 수, attack margin 을 기록하였다.

2.4 Marabou 와의 비교

설정 방식 면에서 Marabou 는 Python 코드 안에서 bound 와 constraint 를 직접 구성하므로 작은 모델에서 직관적이었다. α, β -CROWN 은 YAML + VNNLIB + 실행 환경을 초기에 맞추는 과정이 복잡했으나, 한번 설정 후에는 여러 epsilon 이나 property 를 파일 단위로 batch 처리하기 쉬웠다. 속도 측면에서 이 작은 Wine MLP 에서는 Marabou 가 query 당 1~3 ms 로 매우 빠랐다. α, β -CROWN 의 내부 verifier 시간도 0.03~0.19 초로 짧았지만, wrapper 와 프로세스 초기화 비용을 포함한 wall time 은 약 5 초였다. 다만 α, β -CROWN 은 CNN, ResNet 등 큰 네트워크에서 GPU 기반 bound propagation 과 branch-and-bound 를 활용할 수 있다는 확장성 장점이 있다.

3. α, β -CROWN 의 강점과 한계

3.1 강점

verification 결과가 *verified* / *falsified* / *timeout* 형태로 명확하여 해석이 용이하다. VNNLIB 를 사용하면 property 를 코드와 분리하여 관리할 수 있고, VNN-COMP 벤치마크와도 호환된다. $\epsilon \geq 0.30$ 에서 PGD attack 이 counterexample 을 빠르게 찾아 falsified case 를 효율적으로 처리하였고, $\epsilon \leq 0.10$ 에서는 branch-and-bound 없이 initial CROWN bound 만으로 verified 되어 불필요한 탐색을 피하였다.

3.2 한계

환경 설정과 config 작성이 복잡하다는 점이 주된 한계이다. custom tabular model 하나를 검증하는 데도 ONNX 경로, input shape, VNNLIB, YAML, 실행 경로를 모두 맞춰야 했다. Windows 환경에서는 *auto_LiRPA* submodule import 경로 문제가 있어 *PYTHONPATH* 조정이 필요하였다. 또한 이번 Wine MLP 처럼 입력 차원이 작고 모델이 단순한 경우에는 α, β -CROWN 의 확장성 장점이 크게 드러나지 않았다.

4. 결론

α, β -CROWN 과 Marabou 는 동일한 Wine MLP 와 동일한 normalized robustness property 에 대해 모든 ϵ 에서 일치하는 결론을 냈다. 이 sample 은 $\epsilon \leq 0.10$ 까지 robust 하지만 $\epsilon = 0.30$ 부터 다른 class logit 이 원래 class logit 이상이 되는 입력이 존재한다. 작은 ReLU MLP 에서는 Marabou 가 더 가볍고 직관적이지만, α, β -CROWN 은 VNNLIB 기반의 표준화된 property 관리와 GPU 활용 확장성을 강점으로 가지며, 더 큰 네트워크로의 확장에 유리한 도구임을 확인하였다.